

Estrategias Avanzadas de Análisis de Enriquecimiento Funcional en el Estudio del Envejecimiento Transcriptómico: De la Estadística de Umbral a la Biología de Sistemas en Python

La interpretación de datos transcriptómicos procedentes de comparaciones entre grupos etarios, como adultos frente a individuos de edad avanzada, constituye un desafío fundamental en la gerontología biológica. La identificación de genes diferencialmente expresados (DEGs) es solo el primer paso en un flujo de trabajo que debe culminar en la comprensión de los mecanismos biológicos alterados. El análisis de enriquecimiento de vías (Pathway Enrichment Analysis o PEA) permite transformar una lista de miles de genes, clasificados por sus niveles de expresión, valores de p y cambios de pliegue (log-fold changes), en una narrativa biológica coherente que explica procesos como la senescencia celular, la inflamación crónica sistémica (inflammaging) o el declive de la proteostasis.

Paradigmas Estadísticos en el Análisis de Enriquecimiento

Existen dos enfoques predominantes para realizar el enriquecimiento funcional: el análisis de sobrerrepresentación (Over-Representation Analysis, ORA) y el análisis de enriquecimiento de conjuntos de genes (Gene Set Enrichment Analysis, GSEA). La elección entre uno u otro depende en gran medida de la naturaleza de los resultados obtenidos tras la comparación entre adultos y ancianos y del tipo de pregunta biológica que se desee responder.

Análisis de Sobrerrepresentación (ORA)

El enfoque ORA representa la metodología clásica y más extendida para la interpretación de listas de genes. Se basa en una pregunta estadística sencilla: ¿aparecen los genes de una vía específica en mi lista de DEGs con una frecuencia mayor a la esperada por puro azar?. Para llevar a cabo este análisis, el investigador debe definir un umbral de significancia (por ejemplo, valor de p ajustado < 0.05 y $|\log_2\text{FC}| > 1$) para separar los genes "interesantes" del resto del genoma.

Desde una perspectiva matemática, el ORA utiliza tradicionalmente la distribución hipergeométrica o la prueba exacta de Fisher para calcular la probabilidad de observar el solapamiento detectado. Si se considera un universo de genes N (el "background"), de los cuales n genes son DEGs en el estudio de envejecimiento, y una vía biológica K que contiene m genes totales, la probabilidad de que k genes de esa vía se encuentren en la lista de DEGs se define mediante la fórmula:

Este método es extremadamente rápido y fácil de interpretar, lo que lo hace ideal para una

primera exploración de los datos. Sin embargo, su principal limitación es la dependencia de umbrales arbitrarios. Un gen que se encuentra justo por debajo del umbral de significancia es descartado por completo, perdiéndose información valiosa sobre cambios coordinados pero sutiles en la expresión génica.

Análisis de Enriquecimiento de Conjuntos de Genes (GSEA)

El GSEA fue desarrollado para mitigar las deficiencias del ORA, especialmente en contextos como el envejecimiento, donde muchos procesos biológicos no se alteran mediante cambios drásticos en unos pocos genes, sino a través de variaciones moderadas y coordinadas en toda una red reguladora. A diferencia del ORA, el GSEA no requiere un filtrado previo de los genes; utiliza la lista completa de genes detectados, ordenados según una métrica de rango (como el log2FC o una combinación de este y el valor de p).

El algoritmo calcula una puntuación de enriquecimiento (Enrichment Score, ES) mediante un recorrido por la lista clasificada. La puntuación aumenta cuando se encuentra un gen perteneciente a la vía de interés y disminuye en caso contrario. El valor máximo de esta suma acumulada representa el enriquecimiento de la vía en los extremos de la lista (ya sea sobreexpresado o subexpresado en el grupo de edad avanzada). La significancia se determina habitualmente mediante permutaciones de las etiquetas de las muestras o de los conjuntos de genes.

Característica	ORA (Análisis de Sobrerepresentación)	GSEA (Análisis de Enriquecimiento)
Entrada de datos	Lista filtrada de DEGs (up/down)	Lista completa y clasificada
Dependencia de umbral	Alta (sensible a cortes de p-value/FC)	Nula (independiente de umbrales)
Estadística subyacente	Hipergeométrica / Fisher	Kolmogorov-Smirnov modificada
Captura de señales	Detecta cambios fuertes y evidentes	Detecta cambios sutiles y coordinados
Consideración de rango	Trata a todos los genes DEGs por igual	Pondera los genes según su magnitud de cambio

Implementaciones Nativas en Python para el Análisis de Vías

El ecosistema de Python se ha consolidado como una de las plataformas más robustas para la bioinformática moderna, ofreciendo herramientas que permiten realizar análisis de enriquecimiento de forma eficiente y reproducible sin necesidad de recurrir a entornos externos como R.

GSEAPy: La Referencia Multilingüe Python/Rust

GSEAPy es, sin duda, la herramienta más potente y versátil disponible para usuarios de Python que deseen realizar análisis de enriquecimiento. Se trata de una implementación que combina la facilidad de uso de Python con el alto rendimiento de Rust para el cálculo de estadísticas intensivas. GSEAPy no solo replica los resultados de la herramienta original de Broad Institute,

sino que también ofrece un envoltorio (wrapper) para la API de Enrichr, permitiendo el acceso a cientos de bibliotecas de genes de manera programática.

Para un estudio de envejecimiento (Old vs Adult), GSEApY ofrece varios módulos críticos:

- **Módulo Prerank:** Es ideal cuando ya se dispone de resultados de expresión diferencial. El usuario proporciona una lista de genes clasificada por una métrica (por ejemplo, $\log_2(\text{FC} \times -\log_{10}(p\text{-value}))$) y un archivo de conjuntos de genes (GMT).
- **Módulo GSEA:** Realiza el análisis completo a partir de una matriz de expresión y archivos de fenotipos, calculando la significancia mediante la permutación de las muestras, lo cual es estadísticamente más robusto cuando el número de réplicas es suficiente.
- **Módulo ssGSEA (Single-sample GSEA):** Permite calcular puntuaciones de enriquecimiento para cada muestra individual, lo que facilita la visualización de la variabilidad del envejecimiento entre sujetos y permite realizar correlaciones con otros parámetros clínicos o biológicos.

g:Profiler y la Automatización Mediante gprofiler-official

La herramienta g:Profiler es un estándar en la industria para el análisis de sobrerrepresentación funcional. A través de su paquete oficial para Python, gprofiler-official, los investigadores pueden acceder a la funcionalidad de g:GOST de manera directa desde un Jupyter Notebook. Una de las mayores ventajas de g:Profiler es su capacidad para gestionar automáticamente el mapeo de identificadores de genes (Ensembl, Entrez, Gene Symbols) y su integración con bases de datos como Gene Ontology (GO), KEGG, Reactome y WikiPathways.

En el contexto del envejecimiento, es fundamental utilizar la opción de "background" personalizado que ofrece g:Profiler. Al comparar adultos con ancianos, el universo de genes debe limitarse a aquellos que realmente fueron expresados y detectados en el experimento, evitando así sesgos estadísticos que podrían inflar la significancia de procesos biológicos comunes.

gget: Simplicidad y Eficiencia en la Consulta de Bases de Datos

Para análisis rápidos y minimalistas, la librería gget proporciona un conjunto de herramientas modulares que permiten realizar consultas a bases de datos genómicas con una sola línea de código. El módulo gget enrichr es particularmente útil para realizar un ORA rápido utilizando el motor de búsqueda de Enrichr, permitiendo al investigador explorar rápidamente si su lista de DEGs está asociada con procesos específicos del envejecimiento o fenotipos de enfermedades seniles.

Bases de Datos y Librerías de Genes para el Estudio del Envejecimiento

El éxito de un análisis de enriquecimiento depende críticamente de la calidad y especificidad de las bibliotecas de conjuntos de genes utilizadas. Aunque las bases de datos generales como Gene Ontology (GO) son esenciales, existen recursos especializados en gerontología que proporcionan una resolución mucho mayor para los cambios biológicos que ocurren con la edad.

Recursos de MSigDB (Molecular Signatures Database)

MSigDB es la colección más completa de conjuntos de genes anotados para su uso en GSEA y ORA. Sus colecciones se dividen en varias categorías estratégicas:

- **H (Hallmark Gene Sets)**: Representan estados biológicos bien definidos y son ideales para obtener una visión general de los procesos alterados en el envejecimiento, como la señalización de mTOR, la respuesta al daño del ADN o la inflamación.
- **C2 (Curated Gene Sets)**: Incluye vías metabólicas de KEGG, Reactome y BioCarta, así como firmas extraídas de publicaciones biomédicas. Aquí se encuentran firmas específicas de estudios previos de envejecimiento.
- **C5 (Ontology Gene Sets)**: Contiene los términos de Gene Ontology (BP, CC, MF) y Human Phenotype Ontology, permitiendo una exploración detallada de la función molecular y la localización celular.

Bases de Datos Especializadas en Gerontología: HAGR y AgingReG

Para un análisis de alta precisión en la comparación Old vs Adult, se recomienda integrar conjuntos de genes de bases de datos especializadas:

- **GenAge (The Ageing Gene Database)**: Es el recurso de referencia que contiene genes directamente relacionados con el envejecimiento en humanos y modelos experimentales.
- **CellAge**: Una base de datos dedicada exclusivamente a genes involucrados en la senescencia celular, un proceso cuya acumulación es característica de los tejidos envejecidos.
- **AgingReG**: Se enfoca en las relaciones reguladoras durante el envejecimiento, clasificando si un factor de envejecimiento activa o inhibe a sus genes diana. Este recurso es invaluable para entender no solo qué genes cambian, sino quiénes son los reguladores maestros detrás de esos cambios.
- **GenDR**: Contiene genes asociados con la restricción dietética, permitiendo evaluar si las intervenciones metabólicas podrían estar modulando el perfil transcriptómico observado.

Recurso	Enfoque Principal	Utilidad en Estudios de Edad
GenAge	Genes maestros del envejecimiento	Identificar genes con evidencia causal en longevidad
CellAge	Senescencia celular	Evaluar la carga de células senescentes en tejidos
AgingReG	Redes de regulación	Determinar factores de transcripción alterados con la edad
MSigDB Hallmark	Procesos biológicos robustos	Visión general del estado fisiopatológico
KEGG / Reactome	Vías metabólicas y de señalización	Mapear cambios en el metabolismo energético y proteostasis

Estrategias de Visualización e Interpretación de Resultados

Un análisis de enriquecimiento suele generar largas listas de términos significativos, muchos de

los cuales son redundantes debido a la estructura jerárquica de las ontologías. La visualización avanzada es clave para sintetizar estos resultados en conclusiones biológicas digeribles.

Mapas de Enriquecimiento (Enrichment Maps) y Redes de Similitud

El Mapa de Enriquecimiento organiza los resultados en una red donde los nodos representan vías biológicas y las aristas representan el solapamiento de genes entre ellas. Esta técnica es fundamental para:

1. **Reducir la complejidad:** Agrupa términos redundantes (como "regulación del ciclo celular" y "transición G1/S") en clústeres temáticos claros.
2. **Identificar temas biológicos:** Permite ver si el envejecimiento afecta de manera global a un sistema (por ejemplo, el sistema inmunitario) o solo a componentes específicos.
3. **Comparación visual:** Mediante el uso de colores, se puede representar el enriquecimiento diferencial. Por ejemplo, los nodos rojos pueden indicar vías activadas en ancianos, mientras que los azules representan vías reprimidas.

Visualización con GSEAPy y Seaborn en Python

GSEAPy ofrece funciones integradas basadas en matplotlib y seaborn para generar figuras de alta calidad listas para su publicación :

- **Dotplots:** Muestran los términos más significativos, donde el tamaño del punto indica el número de genes y el color representa el valor de p ajustado.
- **GSEA Plots:** Visualizan el perfil de enriquecimiento a lo largo del ranking de genes, permitiendo identificar los genes de la "leading edge" que más contribuyen a la señal de enriquecimiento.
- **Heatmaps:** Permiten visualizar la expresión relativa de los genes que forman parte de una vía enriquecida a través de todas las muestras de adultos y ancianos, validando la consistencia del cambio biológico.

Consideraciones Críticas para el Análisis Old vs Adult

Para obtener resultados fiables en una comparación de grupos etarios, el investigador debe prestar atención a varios detalles técnicos que a menudo se pasan por alto.

La Importancia del "Universo de Genes" o Background

En el análisis ORA, el cálculo de la significancia depende de cuántos genes se consideran posibles candidatos. Un error común es utilizar el genoma completo como fondo. Si un gen no se expresa en absoluto en el tejido estudiado (independientemente de la edad), no debería formar parte del cálculo probabilístico. Definir el background como el conjunto de todos los genes detectados con al menos una lectura en el experimento asegura que el enriquecimiento sea estadísticamente válido y biológicamente honesto.

Manejo de la Redundancia con orsum y GOMCL

Dado que el envejecimiento afecta a múltiples niveles, es frecuente obtener resultados que parecen indicar cientos de procesos alterados. Herramientas de filtrado como orsum (en

Python) ayudan a simplificar estos resultados manteniendo solo los términos más representativos y significativos de cada grupo funcional. Por otro lado, GOMCL utiliza algoritmos de clustering de grafos (MCL) para identificar estructuras de clústeres en redes de similitud de GO, proporcionando una visión resumida y no sesgada de los temas principales del estudio.

Ranking Basado en Confidencia y Magnitud

Para el análisis GSEA Prerank, no basta con ordenar los genes por su valor de p o por su $\log_2FC$ de forma aislada. Un enfoque robusto consiste en generar una métrica combinada. La fórmula:

permite que los genes que tienen cambios de gran magnitud pero baja significancia estadística, o viceversa, se sitúen en posiciones menos influyentes que aquellos genes que muestran cambios sólidos y estadísticamente irrefutables. Esta métrica es especialmente útil en el envejecimiento, donde la variabilidad biológica entre individuos suele ser elevada y se requiere filtrar el ruido técnico.

Conclusiones y Recomendaciones Metodológicas

Tras revisar las opciones disponibles para el enriquecimiento de vías en un contexto de envejecimiento transcriptómico, se propone un flujo de trabajo optimizado para usuarios de Python:

1. **Preparación de los Datos:** Utilizar los resultados de expresión diferencial ($\log_2FC$ y p -adj) para construir una lista clasificada bidireccional. Separar también los genes sobreexpresados y subexpresados para análisis ORA independientes si se busca mayor claridad en la dirección de los procesos.
2. **Análisis GSEA Prerank con GSEAPy:** Ejecutar el análisis utilizando las colecciones Hallmark (H) y Curated (C2) de MSigDB para capturar señales sutiles de envejecimiento.
3. **Análisis ORA con g:Profiler:** Realizar una validación paralela utilizando g:Profiler con un background personalizado, enfocándose en Gene Ontology Biological Process (GO:BP) y bases de datos especializadas como GenAge.
4. **Integración de Datos de Regulación:** Consultar AgingReG para identificar posibles factores de transcripción responsables de la firma transcriptómica observada.
5. **Visualización de Temas Biológicos:** Generar un Mapa de Enriquecimiento para colapsar términos redundantes y visualizar la arquitectura funcional del envejecimiento en el tejido de interés.

Este enfoque multifacético asegura que no se pierdan cambios coordinados sutiles (gracias a GSEA) y que se identifiquen con precisión los procesos biológicos más robustos (gracias a ORA), proporcionando una imagen completa y mecánicamente rica de las diferencias entre adultos y ancianos. El uso de herramientas nativas de Python como GSEAPy y gprofiler-official garantiza, además, la escalabilidad y la reproducibilidad científica necesarias en la investigación genómica actual.

Fuentes citadas

1. ORA vs GSEA: Choosing the Right Pathway Enrichment Method - MetwareBio, <https://www.metwarebio.com/ora-vs-gsea-pathway-enrichment-omics/>
2. GSEA Analysis

Tutorial: Gene Set Collections and Best Methods - BigOmics Analytics, <https://bigomics.ch/blog/a-short-guide-to-gene-set-and-pathway-enrichment-analysis/> 3. Toward a gold standard for benchmarking gene set enrichment analysis - Oxford Academic, <https://academic.oup.com/bib/article/22/1/545/5722384> 4. GSEA vs ORA: Two key pathway analysis approach... - Pluto Bio, <https://pluto.bio/resources/Learning%20Series/gsea-vs-ora-two-key-pathway-analysis-approach-es-for-next-gen-sequencing-data> 5. Pathway enrichment analysis and visualization of omics data using g:Profiler, GSEA, Cytoscape and EnrichmentMap - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC6607905/> 6. g:Profiler: a web server for functional enrichment analysis and conversions of gene lists (2019 update) | Nucleic Acids Research | Oxford Academic, <https://academic.oup.com/nar/article/47/W1/W191/5486750> 7. gprofiler-official - PyPI, <https://pypi.org/project/gprofiler-official/> 8. A Comparison of Gene Set Analysis Methods in Terms of Sensitivity, Prioritization and Specificity - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC3829842/> 9. Pathway Analysis vs Gene Set Analysis | Advaita Bioinformatics, <https://advaitabio.com/science/pathway-analysis-vs-gene-set-analysis/> 10. GSEAPreranked (v3) - GenePattern, <https://www.genepattern.org/modules/docs/GSEAPreranked/3/> 11. GSEAPy: a comprehensive package for performing gene set enrichment analysis in Python, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9805564/> 12. Functional Enrichment Analysis with clusterProfiler - BTEP Coding Club - Bioinformatics, https://bioinformatics.ccr.cancer.gov/docs/btep-coding-club/CC2023/FunctionalEnrich_clusterProfiler/ 13. gseapy - PyPI, <https://pypi.org/project/gseapy/> 14. Welcome to GSEAPY's documentation! — GSEAPy 1.1.8 documentation, <https://gseapy.readthedocs.io/> 15. GSEAPy - Gene Set Enrichment Analysis in Python · GitHub, <https://github.com/zqfang/gseapy> 16. g:Profiler - Bio.tools, <https://bio.tools/gprofiler> 17. Whole-transcriptome-scale and isoform-resolved spatial imaging of single cells in complex tissues | bioRxiv, <https://www.biorxiv.org/content/10.1101/2025.08.27.672533v1.full-text> 18. g:Profiler – a web server for functional enrichment analysis and conversions of gene lists - BIIT Group, <https://biit.cs.ut.ee/gprofiler/page/docs> 19. g:Profiler: a web server for functional enrichment analysis and conversions of gene lists (2019 update) - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC6602461/> 20. GO enrichment analysis - Gene Ontology, <https://geneontology.org/docs/go-enrichment-analysis/> 21. Introduction - gget - Pachter Lab, <https://pachterlab.github.io/gget/> 22. Efficient querying of genomic reference databases with gget - Oxford Academic, <https://academic.oup.com/bioinformatics/article/39/1/btac836/6971843> 23. pachterlab/gget_examples: Examples for gget (<https://github.com/pachterlab/gget>) · GitHub - GitHub, https://github.com/pachterlab/gget_examples 24. GenAge: The Ageing Gene Database, <https://genomics.senescence.info/genes/index.html> 25. MSigDB - GSEA, <https://www.gsea-msigdb.org/gsea/msigdb> 26. Human MSigDB Collections - GSEA, <https://www.gsea-msigdb.org/gsea/msigdb/collections.jsp> 27. GSEA - MSigDB Collections - Bioinformatics, https://bioinformatics.ccr.cancer.gov/btep/wp-content/uploads/sites/2/GSEA_MSigDB-Collections.pdf 28. Human Gene Set: DEMAGALHAES_AGING_UP, https://www.gsea-msigdb.org/gsea/msigdb/human/geneset/DEMAGALHAES_AGING_UP.html?ex=1 29. AgingReG: a curated database of aging regulatory relationships in humans - Oxford Academic, <https://academic.oup.com/database/article/doi/10.1093/database/baad064/7294220> 30. AgingReG: a curated database of aging regulatory relationships in humans - PubMed, <https://pubmed.ncbi.nlm.nih.gov/PMC10558184> 31. Visualize · Pathway Guide,

https://www.pathwaycommons.org/guide/workflows/rna_seq_to_enrichment_map/visualize/ 32.
 orsum: a Python package for filtering and comparing enrichment ...,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC9308244/> 33. EnrichmentMap:RNA-Seq,
<https://enrichmentmap.org/> 34. Enrichment Map: A Network-Based Method for Gene-Set
 Enrichment Visualization and Interpretation | PLOS One - Research journals,
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0013984> 35. Module 3 Lab:
 GSEA Visualization | Pathway and Network Analysis of -Omics Data (June 2023) - GitHub
 Pages, https://baderlab.github.io/CBW_Pathways_2023/gsea_mod3.html 36. (10-12) Navigation
 and interpretation of the enrichment map | Pathway enrichment analysis and visualization of
 omics data using g:Profiler, GSEA, Cytoscape and EnrichmentMap,
https://baderlab.github.io/EnrichmentMap_Protocol/navigation-and-interpretation-of-the-enrichment-map.html 37. Genomic Data Visualisation with Python - physalia-courses,
<https://www.physalia-courses.org/courses-workshops/genomic-data-viz-python/> 38. Gene Set
 Enrichment Analysis with ClusterProfiler,
<https://learn.gencore.bio.nyu.edu/rna-seq-analysis/gene-set-enrichment-analysis/> 39. How to
 use GSEAPy for pathway enrichment analysis | by Kuan Rong Chan, Ph.D. - Medium,
<https://medium.com/omics-diary/how-to-use-gseapy-for-pathway-enrichment-analysis-67a1aab1002d> 40. GSEAPy/gseapy/plot.py at master · zqfang/GSEAPy · GitHub,
<https://github.com/zqfang/GSEAPy/blob/master/gseapy/plot.py> 41. Pathway enrichment analysis
 of -omics data - bioRxiv, <https://www.biorxiv.org/content/10.1101/232835v1.full-text> 42. GOMCL:
 a toolkit to cluster, evaluate, and extract non-redundant associations of Gene Ontology-based
 functions - PMC, <https://pmc.ncbi.nlm.nih.gov/articles/PMC7146957/>