


```
body { font-family: Helvetica, sans-serif; font-size: 12pt; } h1 { font-size: 24pt; font-weight: bold; color: #333; } h2 { font-size: 18pt; font-weight: bold; border-bottom: 1px solid #ccc; } code { font-family: Courier; background-color: #f4f4f4; } pre { background-color: #f4f4f4; padding: 10px; border: 1px solid #ddd; }
```

Auditora de Validacin Visual: Hito V4-Clean

Este reporte sirve como bitcora interactiva para revisar y comentar sobre la calidad del dataset **V4-Clean (Gold Standard)** siguiendo la cronologa real del flujo de trabajo.

1. Efecto de scAR en RNA Ambiental (Sopa)

Effect



Archivo:

Important


Paso Inicial del Flujo: La remocin de ruido ambiental fue el primer paso crtico. Se utiliz **scAR** para modelar la "sopa" y purificar las cuentas. - Se grafic la expresin de marcadores clsicos de RNA ambiental (Eritrocitos: HBB, HBA1, HBA2; Clulas B: IGHG1, IGKC, JCHAIN; Monocitos: LYZ) comparando las cuentas crudas (raw_counts) vs. las cuentas corregidas por **scAR** (X). - **Resultado:** Se observa una reduccin drstica de estos transcritos ambientales. Esto asegura que la seal detectada sea endgena de las clulas NK.

Cdigo de Validacin:

```
# Marcadores de ruido ambiental (Sopa)
markers = {'Erythrocytes': ['HBB', 'HBA1', 'HBA2'],
'B cells': ['IGHG1', 'IGKC', 'JCHAIN'],
'Monocytes': ['LYZ']}

# Comparacin visual entre capas
sc.pl.stacked_violin(adata, markers, layer='raw_counts', title='Raw Counts
(Con Ruido)')
sc.pl.stacked_violin(adata, markers, title='scAR Corrected (Seal Limpia)')
```

2. Control de Calidad Adaptativo (DDQC)



Note

Contexto de Aplicacin: Tras la limpieza de scAR y la seleccin inicial del grupo celular, se aplic **DDQC** (Data-Driven Quality Control). - **Orden de Proceso:** Segn los registros de `2.0QC.py`, el control de calidad se realiz **despus** de aislar la poblacin de inters (`1.5cell_group_filtered`), permitiendo umbrales especficos para la fisiologa de las clulas NK (ej. mayor tolerancia mitocondrial por su estado metablico activo). - **Distribucin Bimodal (Diagnstico Integral):** - **Rechazo de Hipotesis Inicial:** Inicialmente se plante que la bimodalidad reflejaba subpoblaciones biolgicas (CD56dim vs CD56bright). Sin embargo, el anlisis de estratificacin descart esta teora al no encontrar una correlacin entre marcadores de pureza y los picos de densidad. - **Origen Tcnico Dominante (Assay):** El Anlisis de Componentes Principales (PCA) revel que el **65.6% de la varianza en PC1** (el eje de mayor variacin) est explicado directamente por el tipo de Assay tcnico. Las diferencias de sensibilidad entre 10x v2, v3 y Smart-seq2 desplazan artificialmente las poblaciones hacia picos de "alta" o "baja" complejidad. - **Origen Biolgico Potente (Age Group):** A pesar del ruido tcnico, el anlisis cuantific que el **22.68% de la varianza** es explicada genuinamente por el factor `age_group`. Este hallazgo es fundamental para la tesis, ya que confirma una "**Contraccin Transcriptmica**" real: las clulas NK de individuos mayores (Old) presentan una reduccin significativa en la cantidad de transcritos y diversidad gnica frente a los jvenes (Young), lo que explica por qu la distribucin se "estira" hacia valores menores en el grupo de edad avanzada.

Cdigo de Diagnstico (Bimodalidad):

```
import seaborn as sns
import matplotlib.pyplot as plt

fig, axes = plt.subplots(1, 2, figsize=(16, 6))

# Estratificacin por Assay (Impacto Tcnico)
sns.histplot(data=adata.obs, x='n_genes_by_counts', hue='assay', bins=100,
             element='step', common_norm=False, stat='density', ax=axes[0])
axes[0].set_xscale('log')

# Estratificacin por Grupo de Edad (Impacto Biolgico)
sns.histplot(data=adata.obs[adata.obs['n_genes_by_counts'] < 8000],
             x='n_genes_by_counts', hue='age_group', bins=100,
             element='step', common_norm=False, stat='density', ax=axes[1])
plt.show()
```

Archivos de Diagnstico (Visualizacin Directa): - [Estratificacin por Assay \(Log Scale\)](#) - [Distribucin de Cuentas por Edad \(Log Scale\)](#) - [Estratificacin por Age Group \(Zoom Complexity\)](#) - [Infografa de Varianza Explicada \(PCA\)](#)

Comentarios y Veredicto del Consejo Nova: * **Duda Original:** "Necesitamos aplicar de nuevo DDQC e implementar un filtro adaptativo por cuentas ribosomales tras ver esta bimodalidad?" * **Veredicto Cientfico:** Regresar a filtrar por clulas basndose en cuentas ribosomales sera **contraproducente**. Las clulas NK tienen una actividad traduccional alta por naturaleza biolgica. Filtrarlas reducir la representatividad de estados funcionales activos (ej. CD56bright) y mermara el poder estadstico de los 547 donantes. * **Justificacin V4-Clean:** El hallazgo de que los *loadings* del PC1 tcnico son abrumadoramente ribosomales valida que la **exclusin matricial (V4-Clean)** es la solucin ptima. Eliminamos el ruido del "sensor" (el kit de secuenciacin) sin eliminar al "sujeto" (la clula del donante).

Cdigo de Auditora de Varianza (PCA):

```
import statsmodels.api as sm

# Calcular varianza explicada por cada covariable en el PC1
pc1 = adata.obsm['X_pca'][:, 0]
df = pd.DataFrame({'PC1': pc1, 'age_group': adata.obs['age_group'],
                  'assay': adata.obs['assay']})

r2_assay = sm.OLS.from_formula('PC1 ~ C(assay)', data=df).fit().rsquared
r2_age = sm.OLS.from_formula('PC1 ~ C(age_group)', data=df).fit().rsquared


print(f"R de Assay (Tcnico): {r2_assay:.2%}")
```

```
print(f"R de Age Group (Biológico): {r2_age:.2%}")


# Identificar genes conductores (Loadings)
loadings = pd.DataFrame(adata.varm['PCs'], index=adata.var_names,
                        columns=[f'PC{i+1}' for i in range(adata.varm['PCs'].shape[1])])
top_genes = loadings.nlargest(10, 'PC1')['PC1']
print("\n\nTop 10 Genes Conductores del Sesgo (Principalmente
RPS/RPL):\n", top_genes)
```

3. Remoción de Dobletes (SOLO)

Distributi



UMAP2



Archivos: |

Important

Paso 3 del Flujo: Tras asegurar la viabilidad celular con DDQC, se procedi a identificar y remover dobletes tcnicos utilizando el modelo **SOLO** (dentro del ecosistema *scVI*). - **Resultados del Gold Standard:** El dataset actual contiene **0% dobletes** (191,903 singlets). - **Distribucin de Scores:** La mayora de las clulas remanentes presentan un `doublet_score` cercano a 0, lo que garantiza que no estamos arrastrando artefactos de dos clulas capturadas en una misma gota. - **UMAP:** La visualizacin del score sobre el UMAP no muestra "islas" de alta puntuacin, validando la homogeneidad del dataset.

Cdigo de Validacin:


```
import seaborn as sns
import matplotlib.pyplot as plt

if 'doublet_score' in adata.obs:
    plt.figure(figsize=(8, 4))
    sns.histplot(adata.obs['doublet_score'], bins=50, kde=True,
color='purple')
    plt.title('Distribucin de SOLO Doublet Scores (Singlets Retenidos)')
    plt.show()

sc.pl.umap(adata, color='doublet_score', cmap='magma', title='SOLO Doublet
Score UMAP')
```

4. Pureza de Linaje (NK vs B/T)

Lineage Purity Validation (Go



Archivo:

[!SUCCESS] **Validacin de Identidad:** Confirmamos que tras scAR y DDQC, el dataset es extremadamente puro. - Expresin robusta de marcadores NK (*NKG7*, *GNLY*, *NCAM1*). - Seal nula/mnima de T-cells (*CD3D*, *TRAC*) y B-cells (*CD79A*, *MS4A1*).


Cdigo de Validacin:

```
canonical_markers = {
'NK Cells': ['NCAM1', 'FCGR3A', 'GNLY', 'NKG7'],
'T Cells': ['CD3D', 'CD3E', 'TRAC'],
'B Cells': ['CD79A', 'MS4A1']
}

sc.pl.dotplot(adata, canonical_markers, groupby='dataset_id',
standard_scale='var',
title='Pureza de Linaje (Dataset Integrado)')
```

5. Exclusin de Genes V4 (Ribosomales/TCR/IG)

Genes Excl



Archivo:


Tip

Filtrado Administrativo Final: Preparacin final para el anlisis de enriquecimiento, eliminando sesgos dominantes (RPS/RPL) y trazas de TCR/IG.

6. Estructura del Dataset (UMAP)

Gold Standard NK C

UMAP2



UMAP1

7. Resumen del Inventario (Gold Standard)

Archivo: [05DatasetSummary.txt](#)

- **Total de Clulas:** 191,903
- **Total de Donantes:** 547 (Confirmado por el usuario como cifra correcta).
- **Firma de Genes DE:** 182 genes (Aclarado por el usuario).